# 100 años

## de calidad académica



UNIVERSIDAD LIBRE
Vigilada Mineducación

centenario
EDUCANDO EN LIBERTAD PARA LA JUSTICIA Y LA PAZ

CAMINANDO EN LA EXCELENCIA

REACREDITACIÓN INSTITUCIONAL
MULTICAMPUS 2021-2027
ALTA CALIDAD
Resolución MEN n.º 015865 (25-08-2021)

Agosto de 2026.

# Ciencia de Datos

## “Tomando decisiones basados en conocimiento”

Título

**Producto de datos para el análisis integrado del comercio de importación y el tráfico portuario de Buenaventura**


Autores

**Juan Manuel Tejada Fajardo · Jesús Alejandro Guerrero**

Director

**Ing. Fabián Castillo · Universidad Libre — Seccional Cali**

Agosto de 2026.

# Contenido de la sustentación

Quince minutos repartidos en tres momentos

15 minutos

**1 · Información general**
Introducción y procesos generales

**2 · Planteamiento del problema**
Descripción, antecedentes, formulación y sistematización

**3 · Objetivos**
General y específicos

**4 · Justificación, alcance y delimitación**
Por qué, hasta dónde y con qué

**5 · Marco de referencia**
Teórico, conceptual, contextual y legal

**6 · Metodología**
Fundamento de la ciencia de datos

**7 · Ingeniería y despliegue del producto**
Entorno, cuadro de mando y demostración en vivo

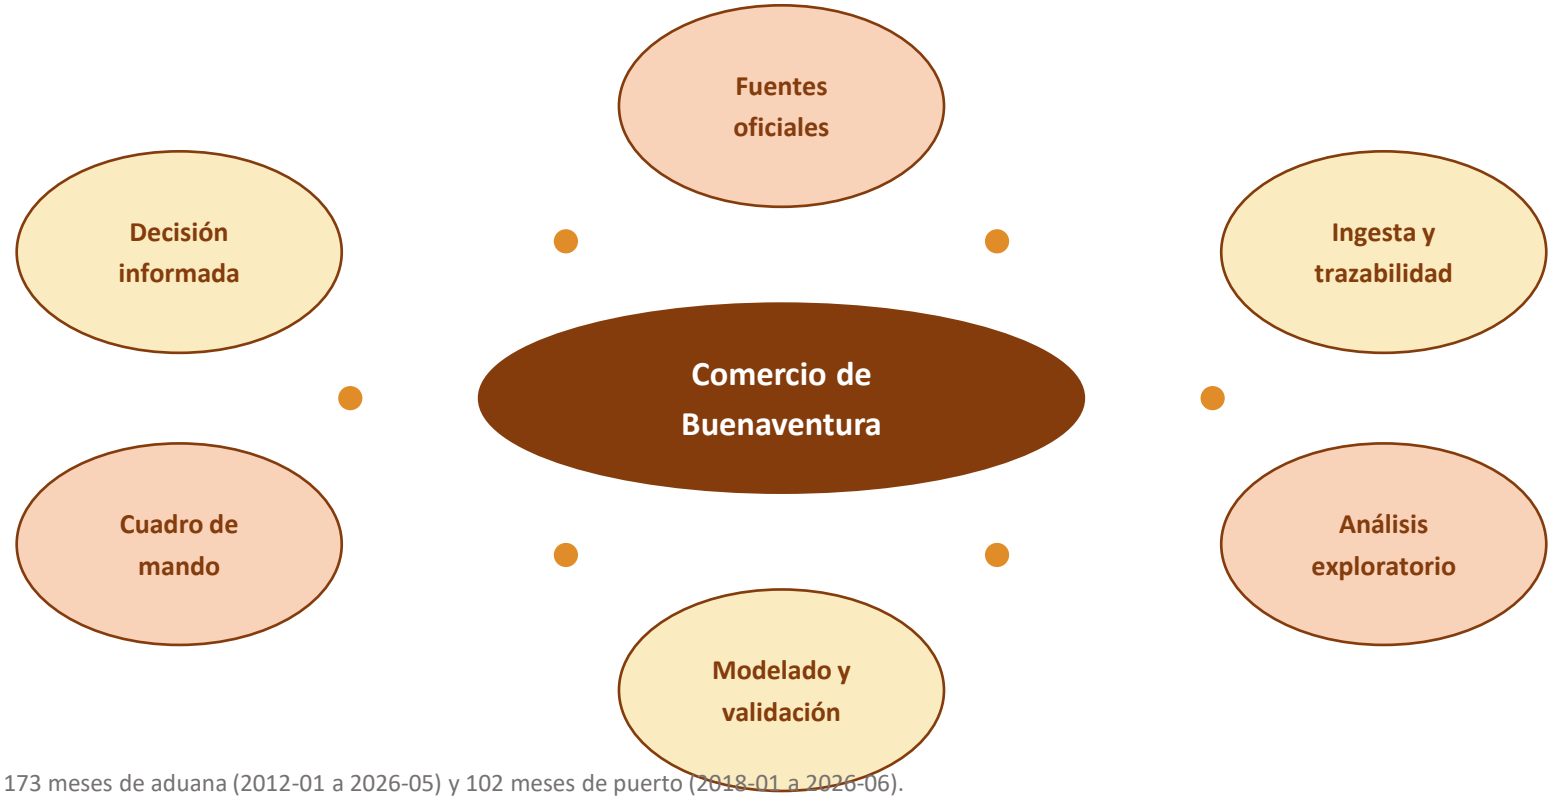
**8 · Modelo de negocio y comunicación**
Propuesta de valor y difusión

**9 · Cierre**
Conclusiones, recomendaciones y fuentes

**Contexto 3 min · Producto de datos 10 min · Cierre 2 min**

# Introducción

El ciclo que recorre el proyecto, de la fuente oficial a la decisión




Dos dominios oficiales integrados: 173 meses de aduana (2012-01 a 2026-05) y 102 meses de puerto (2018-01 a 2026-06).

# Procesos generales

Mapa de procesos: cuatro capas de datos con evidencia en cada paso

**RAW**
Fuente inmutable con hash SHA-256

**LANDING**
Normalización de formatos

**TRUSTED**
Series validadas y reconciliadas

**SURFACE**
Evidencia lista para consumo

**PRODUCTO**
Cuadro de mando y documento

### Control de entrada

Cada archivo se registra con su huella digital y su fecha de descarga antes de ser tocado.

### Control de proceso

Reconciliación mes a mes contra el total publicado y bitácora de defectos de la fuente.

### Control de salida

90 pruebas automatizadas y comprobaciones de estilo.

Ningún resultado del producto existe sin un archivo de evidencia que lo respalde y sin la pregunta del catálogo que lo originó.

# Planteamiento del problema

Mapa conceptual: qué impide hoy leer el comercio de Buenaventura como un solo fenómeno

**Conceptos no equivalentes**
El peso neto aduanero y las toneladas portuarias no miden lo mismo.

**Sin llave común**
No hay identificador público que una una declaración con un movimiento de carga.

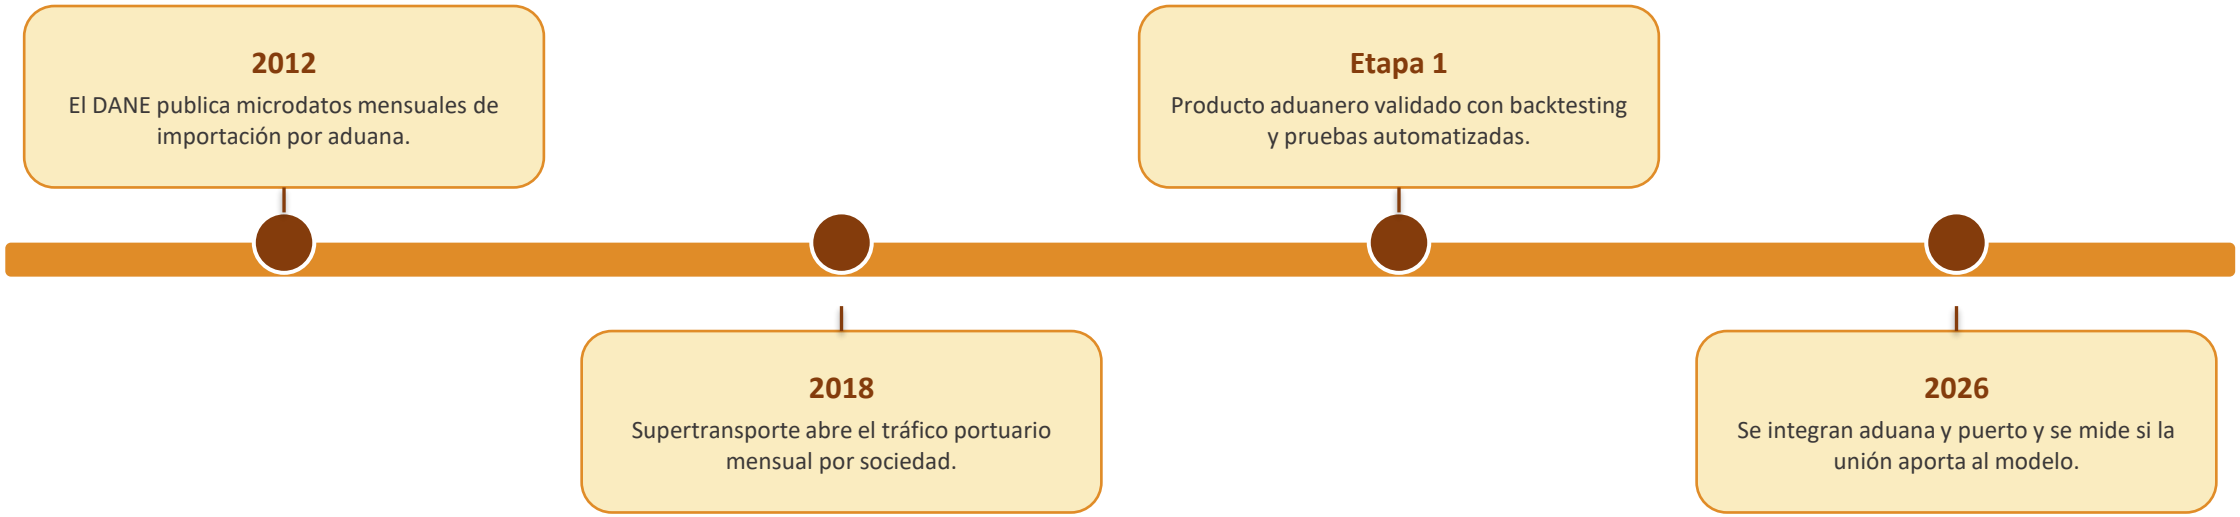
**La información existe, pero está partida**

**Lectura incompleta**
Con una sola fuente no se distingue si un mes cambió por valor o por volumen.

**Dos registros separados**
La aduana mide declaraciones; el puerto mide toneladas movilizadas.

# Antecedentes

Línea de tiempo: de las fuentes disponibles al producto integrado




El dataset portuario resultó ser mensual y descargable por API, no solo trimestral en PDF como se consideró al comienzo.

# Formulación del problema

**¿Cómo desarrollar un producto de datos reproducible que integre información aduanera y portuaria de Buenaventura, permita monitorear y explicar indicadores agregados, pronostique únicamente aquellos con historia y calidad suficientes, comunique la incertidumbre de forma calibrada y no afirme relaciones que las fuentes no permiten sostener?**

La última condición de la pregunta admite una respuesta negativa, y el proyecto la mide en lugar de suponerla.

# Sistematización del problema

Diagrama de árbol: la pregunta central abierta en cuatro preguntas verificables

**¿Qué aporta integrar aduana y puerto en Buenaventura?**

### ¿Con qué llave?

Qué tipo de unión admiten las fuentes: directa, agregada o solo contextual.

### ¿Con qué calidad?

Qué cobertura, continuidad y defectos tiene cada serie una vez reconciliada.

### ¿Mejora el pronóstico?

Si añadir variables portuarias reduce el error del pronóstico aduanero.

### ¿Qué no se puede responder?

Qué preguntas quedan cerradas por ausencia de fuente pública.

# Objetivo general

**Desarrollar y validar un producto de datos reproducible que integre información aduanera y portuaria de Buenaventura para monitorear, explicar y pronosticar indicadores agregados, conservando la trazabilidad desde la fuente oficial hasta la salida de consumo.**

**Trazable**
Cada cifra remite a un archivo de evidencia.

**Validado**
Backtesting con ventana expansiva y líneas base.

**Honesto**
Lo que la fuente no sostiene se declara no viable.

# Objetivos específicos

Los ocho objetivos del documento, cada uno con el archivo que demuestra su cumplimiento

**Producto de datos integrado, trazable y validado**

### 1 · Evaluar la viabilidad de fuentes en cuatro dominios

6 fuentes evaluadas: 2 integradas, 2 de contexto, 2 descartadas.

### 2 · Construir series mensuales reconciliadas

173 meses aduaneros y 102 portuarios, continuos.

### 3 · Ejecutar las 52 preguntas y conservar la evidencia

38 ejecutadas, 4 parciales y 10 no viables.

### 4 · Declarar el tipo de integración posible

Integración agregada por mes; ninguna directa.

### 5 · Determinar qué indicadores pueden pronosticarse

4 elegibles de 7 evaluados.

### 6 · Medir si la integración mejora el pronóstico

No lo mejora: pasa de 6,082 % a 6,575 %.

### 7 · Comunicar la incertidumbre con cobertura medida

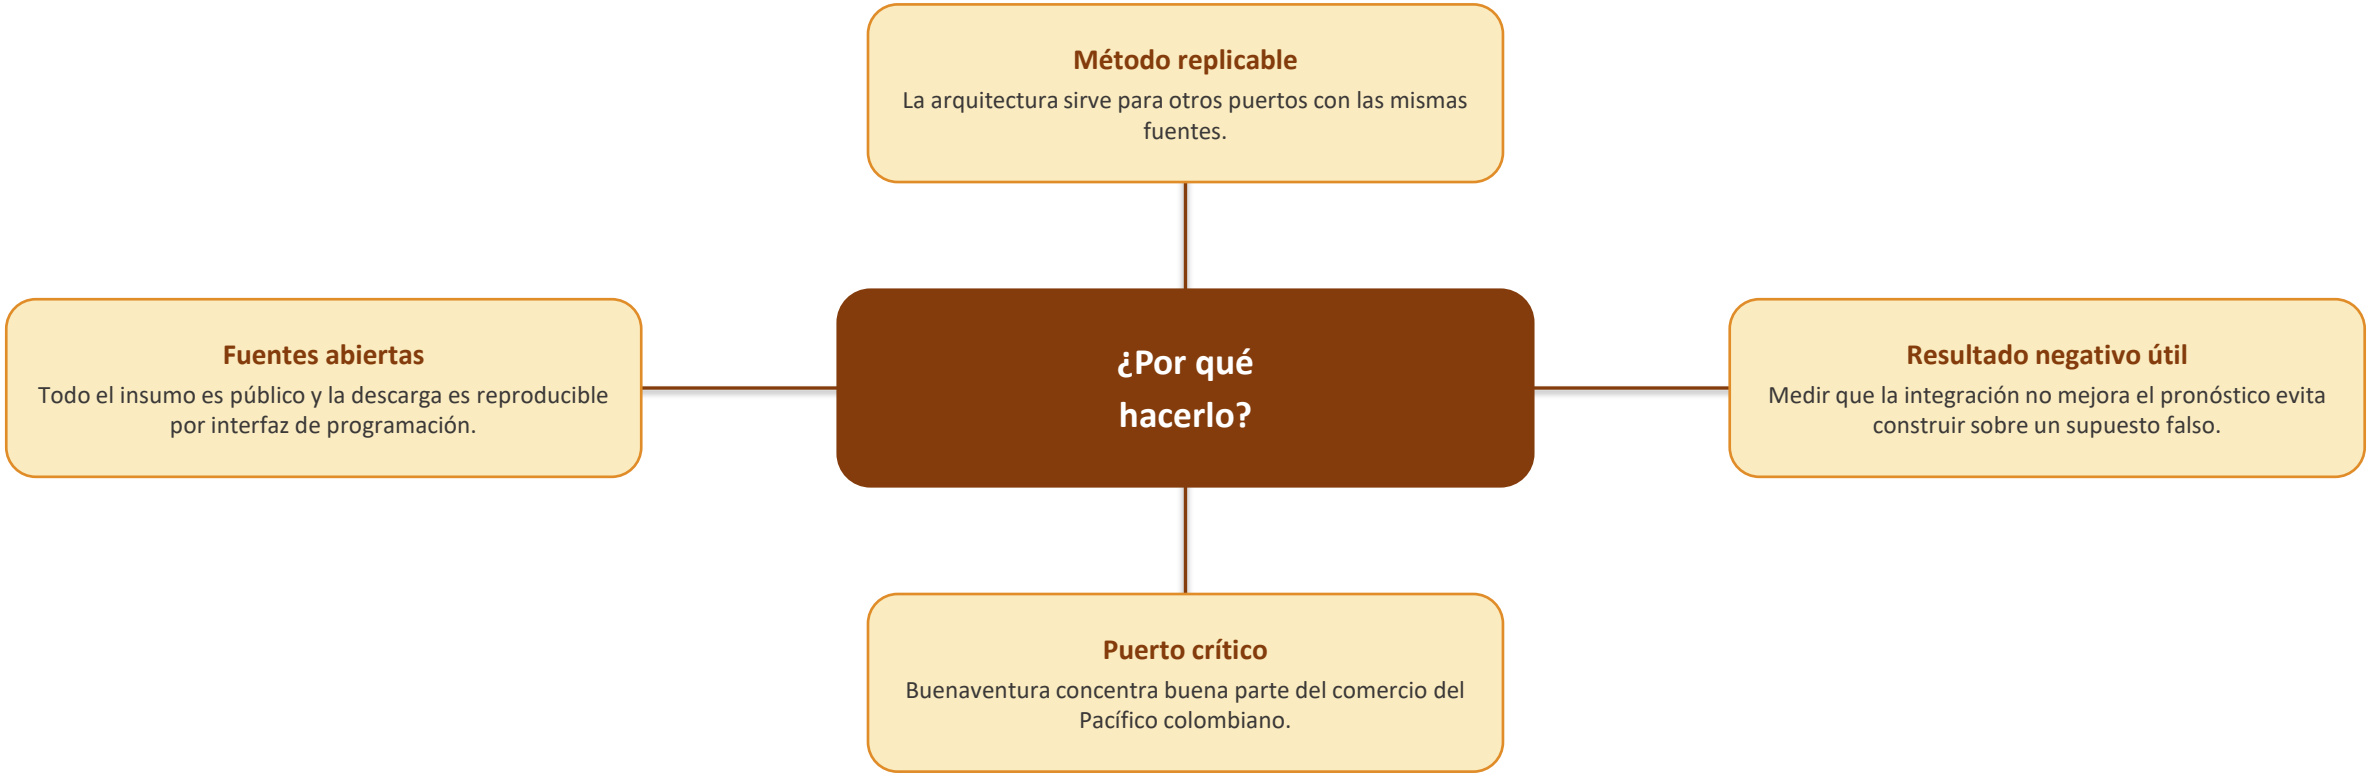
Cobertura empírica entre 75,0 % y 91,7 %.

### 8 · Documentar con evidencia lo no viable

10 preguntas cerradas con búsqueda documentada.

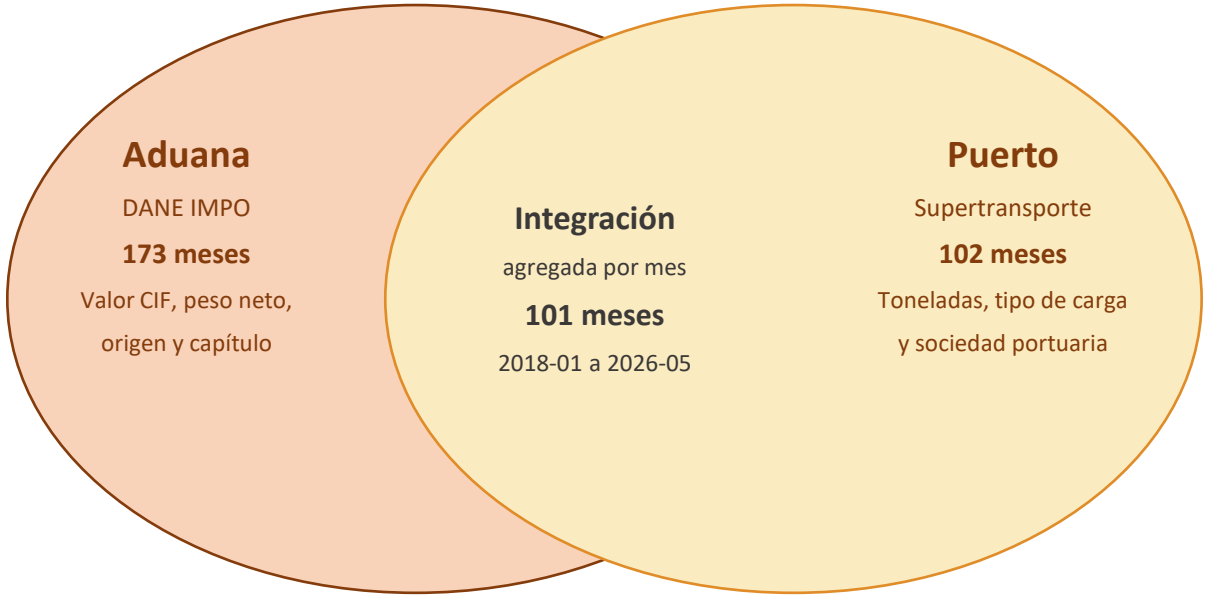
# Justificación práctica

Mapa mental: por qué el ejercicio tiene valor aunque parte de sus resultados sean negativos



# Alcance

Diagrama de Venn: lo que cada dominio aporta y lo que solo se ve al cruzarlos




La intersección es temporal, no de registro: se cruzan meses, nunca una declaración con un movimiento de carga.

# Delimitación

Tabla comparativa: qué entra, qué queda fuera y por qué

| Dimensión | Dentro del proyecto | Fuera del proyecto | Razón |
|---|---|---|---|
| Espacial | Zona portuaria de Buenaventura y aduana 35 | Otros puertos del país | El objeto de estudio es un solo nodo |
| Temporal | Aduana 2012-01 a 2026-05 | Antes de 2012 y después del último corte | Cobertura efectiva de los microdatos |
| Temática | Importación, tráfico portuario y contexto | Exportación como objeto de modelado | La aduana 35 registra importación |
| Operacional | Toneladas y tipo de carga por sociedad | Arribos, banderas, tiempos de atención | Sin fuente pública tabular histórica |
| Metodológica | Modelos lineales regularizados con validación temporal | Modelos de caja negra | Muestra corta y exigencia de interpretabilidad |

De las 52 preguntas del catálogo, 10 quedaron cerradas como no viables con la evidencia de dónde se buscó la fuente.

# Marco teórico y conceptual

Mapa conceptual: los conceptos que sostienen las decisiones técnicas

### Series de tiempo

Autocorrelación, estacionalidad y tendencia como estructura a explotar.

ACF del CIF en el rezago 1: 0,917.

### Validación temporal

Ventana expansiva y pronóstico a un paso: nunca se entrena con el futuro.

24 cortes de backtest sobre el valor CIF.

### Líneas base

Un modelo solo aporta si supera repetir el último valor.

Naive 1 sobre el CIF: 6,956 %.

### Incertidumbre

Intervalos conformales calibrados sobre errores pasados, no supuestos.

Cobertura nominal 80 %.

### Concentración

El índice de Herfindahl-Hirschman mide reparto, no capacidad instalada.

Umbral de concentración: 2.500 puntos.

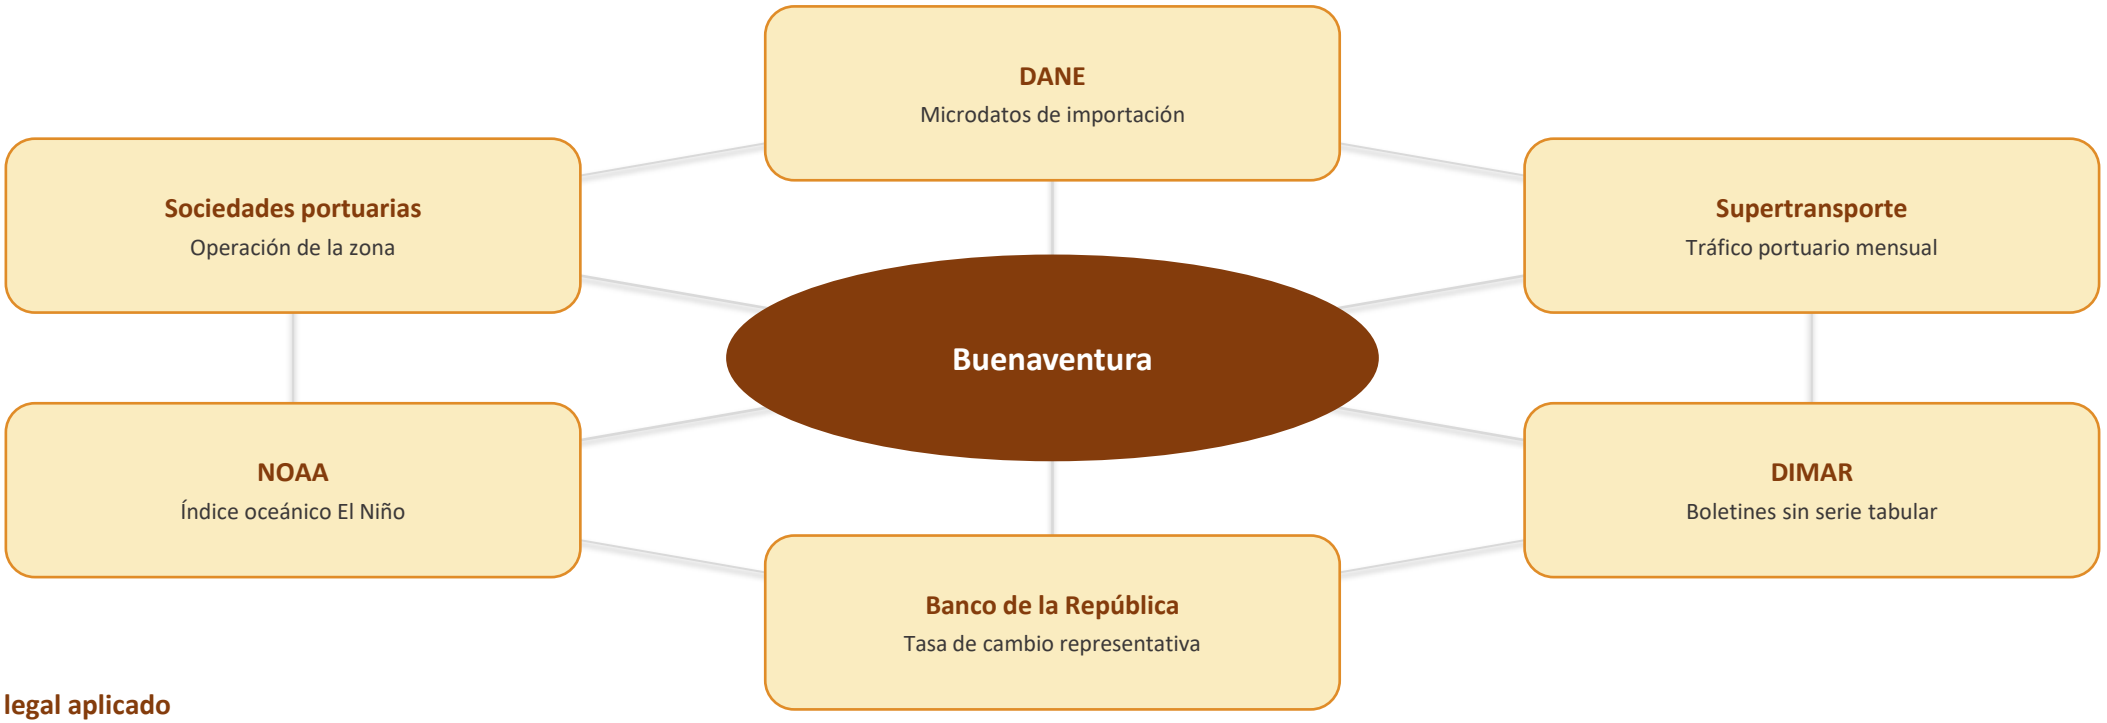
### Trazabilidad

Cada resultado nace de una pregunta del catálogo y deja un archivo.

Catálogo cerrado de 52 preguntas.

# Marco contextual y legal

Mapa de red institucional y jerarquía normativa de las fuentes



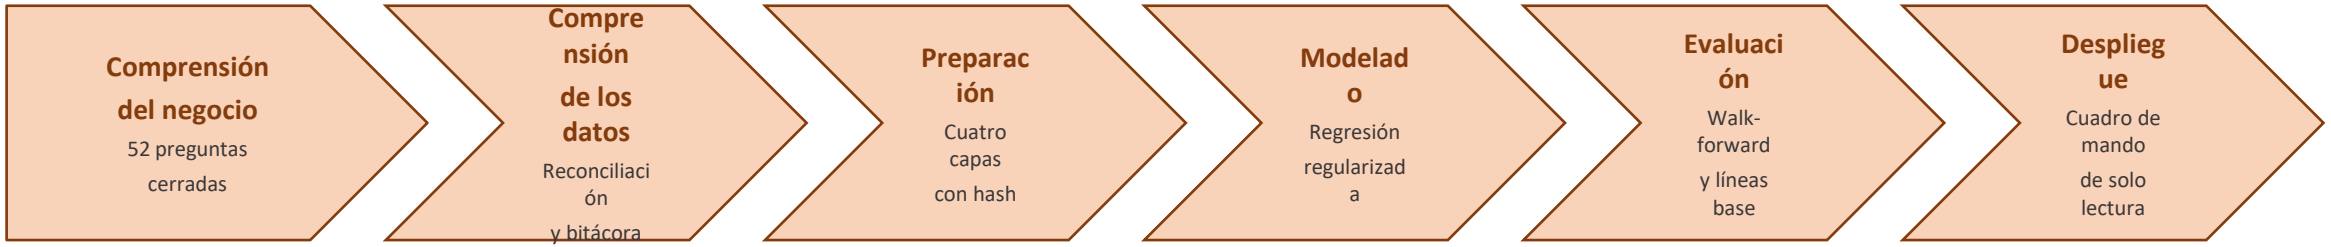

## Marco legal aplicado

1. Ley 1712 de 2014, transparencia y acceso a la información pública · 2. Ley 1581 de 2012, protección de datos: el proyecto solo usa agregados · 3. Licencia CC BY-SA 4.0 del conjunto portuario, citada en cada uso · 4. NTC 1486 y APA séptima edición

# Metodología

Producto · 10 min

Diagrama de flujo: el fundamento de ciencia de datos aplicado al proyecto




### Sin fuga temporal

Todas las variables entran rezagadas y los escaladores se ajustan dentro de cada corte, nunca sobre la serie completa.

### Contra líneas base

Cada modelo compite contra repetir el último valor, repetir el mismo mes del año anterior y la deriva.

### Con ablación

Se entrenan cinco configuraciones de variables para aislar qué grupo aporta y cuál estorba.

La métrica principal es el error porcentual absoluto ponderado sobre 24 cortes de validación, no el ajuste sobre los datos de entrenamiento.

Agosto de 2026.

# El producto de datos

Propósito, público objetivo y valor agregado

Producto · 10 min

### Propósito

Leer en un solo lugar el comercio de importación y el tráfico portuario de Buenaventura, distinguiendo qué parte de un cambio viene del valor y qué parte del volumen físico.

### Público objetivo

Analistas de comercio exterior, equipos de planeación logística y observatorios académicos que hoy consultan las dos fuentes por separado.

### Valor agregado

Un contraste que ninguna fuente muestra sola, cifras con evidencia rastreable y un pronóstico que declara su margen de error en lugar de esconderlo.

### Lo que sí hace

Describe, compara dominios, pronostica lo que se puede pronosticar y publica el error de cada pronóstico.

### Lo que no hace

No estima congestión, tiempos de atención ni buques. No imputa valores ausentes: avisa de que faltan.

# Ingeniería del producto

Entorno de desarrollo, componentes y reutilización

Producto · 10 min

| Componente | Contenido |
|---|---|
| Módulos de dominio | Aduana, puerto e integración |
| Módulos comunes | Métricas, modelos, calidad y trazabilidad |
| Suites de prueba | 90 pruebas automatizadas |
| Revisión de estilo | Sin hallazgos |
| Cuadros de trabajo | Entorno y análisis exploratorio |
| Cuadro de mando | Siete vistas de solo lectura |

### Entorno reproducible

Dependencias fijadas en un archivo de requisitos; la ruta raíz se deriva del propio archivo, sin rutas absolutas en ningún módulo.

### Ejecución local y en la nube

El mismo paquete detecta si corre en el equipo o en un entorno de cuadernos en la nube y reapunta las rutas sin duplicar el sistema de carpetas.

### Continuidad sobre lo que ya funcionaba

Se conservaron los módulos que ya estaban validados y se ajustaron únicamente los puntos que presentaban problemas.

La reutilización es deliberada: métricas, intervalos, líneas base y trazabilidad son agnósticos al dominio y sirven igual para toneladas que para valor.

Agosto de 2026.

# Trazabilidad de punta a punta

De la pregunta al archivo de evidencia y del archivo a la diapositiva

Producto · 10 min

**Pregunta**
Catálogo cerrado
P01 a P52

**Ejecución**
Módulo o celda
del cuaderno

**Evidencia**
Archivo con
huella digital

**Cifra**
Catálogo de
cifras verificadas

**Publicación**
Documento y
cuadro de mando

**Ejecutadas**
38
con archivo de salida verificable

**Parciales**
4
ejecutadas con limitación declarada

**No viables**
10
con evidencia de dónde se buscó

**Sin justificar**
0
ninguna quedó sin respuesta

El cuaderno de análisis produce 55 figuras y 57 archivos de evidencia, y se ejecuta de punta a punta sin errores. La construcción del documento falla si alguien escribe una cifra que no esté en el catálogo.

Producto · 10 min

# La integración no mejora el pronóstico

Resultado central. Ablación multidominio sobre el valor CIF, 24 cortes de backtesting con ventana expansiva

| Conjunto de variables | Variables | Error (WAPE) | Frente a A |
|---|---|---|---|
| **B · historia propia + calendario** | 7 | **5,875 %** | **+0,207 pp** |
| A · historia propia | 5 | 6,082 % | — |
| D · A + contexto (tasa de cambio, El Niño) | 9 | 6,133 % | −0,051 pp |
| E · integrado completo | 16 | 6,167 % | −0,085 pp |
| **C · A + puerto** | 10 | **6,575 %** | **−0,493 pp** |
| Base · repetir el último valor | 0 | 6,956 % | −0,874 pp |

### Por qué ocurre

Ambas fuentes miden el mismo comercio subyacente y comparten el mismo rezago de publicación. El puerto no añade información que la historia del propio valor no contenga ya, y sí consume grados de libertad sobre una muestra corta.

### Qué significa para el producto

El valor de la integración no es predictivo: es explicativo. Sirve para responder si un mes cambió por valor o por volumen y para localizar por qué sociedad portuaria pasa la carga.

Las cinco configuraciones superan a las tres líneas base: el modelo aporta sobre no hacer nada. Lo que no aporta es la integración. Se reporta tal cual se midió.

# Concentración por sociedad portuaria

Producto · 10 min

Lo que solo se ve integrando. Índice de Herfindahl-Hirschman en tres dimensiones del mismo comercio

**Capítulo arancelario**
433,74
desconcentrado

**País de origen**
1.351,38
desconcentrado

**Sociedad portuaria**
3.514,24
concentrado

Buenaventura importa mercancía variada desde orígenes variados, pero la mueve por muy pocas sociedades portuarias.

| Sociedad portuaria | Participación 2018–2026 |
|---|---|
| **Sociedad Portuaria Regional de Buenaventura** | **51,36 %** |
| Sociedad Puerto Industrial Aguadulce | 25,28 % |
| Sociedad Portuaria Terminal de Contenedores | 13,73 % |
| Grupo Portuario | 6,01 % |
| Compañía de Puertos Asociados | 3,62 % |

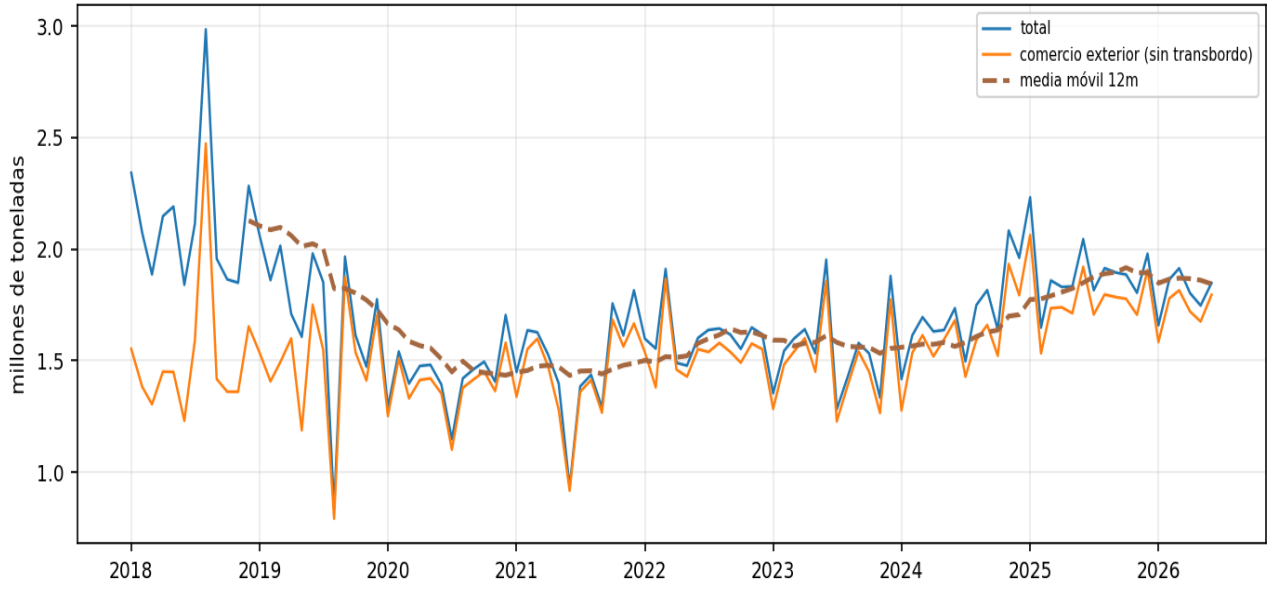
| Año | Índice | Sociedades que reportan |
|---|---|---|
| 2018 | 4.722 | 5 |
| 2023 | 2.988 | 5 |
| 2025 | 3.740 | 5 |
| **2026 · seis meses** | **4.217** | **3** |
| **2025 recalculado con esas tres** | **4.096** | **3** |

El índice mide reparto de toneladas reportadas: no mide capacidad instalada, utilización ni posibilidad real de sustitución. El salto de 2026 se explica sobre todo por el cambio de cobertura del reporte.

# La caída portuaria es transbordo

Lo que esconde un total. Descomposición del tráfico de la zona portuaria por tipo de flujo

Producto · 10 min




Unidad: millones de toneladas · Periodo: 2018-01 a 2026-06 · Fuente: Superintendencia de Transporte — tráfico portuario 5r3g-zv5z · Fecha de corte: 2026-06

El transbordo es carga que cambia de buque sin entrar ni salir del país: pesa 9,5 % del total movilizado y sumarlo al comercio exterior infla la cifra. La caída del total no es una caída del comercio.

**Importación**
19,6 %
variación del periodo

**Exportación**
1,3 %
variación del periodo

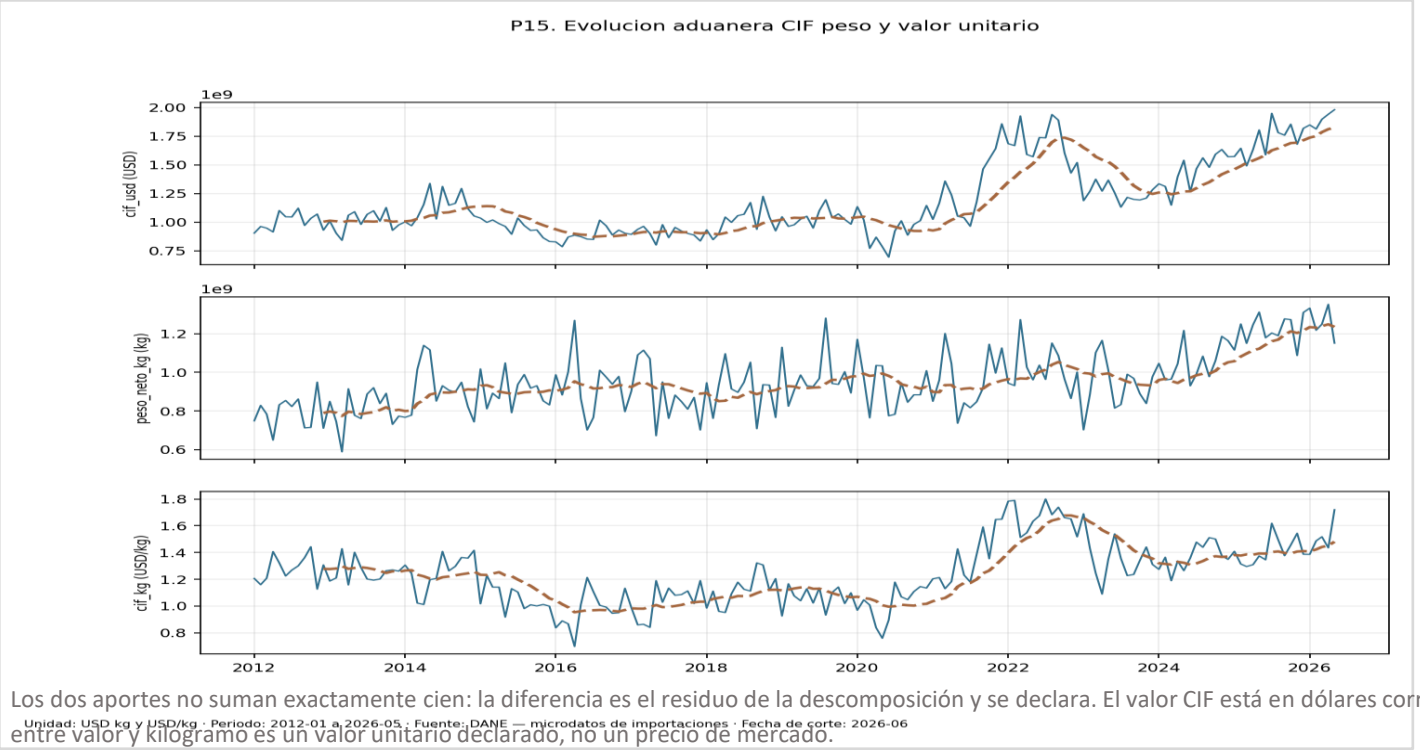
**Transbordo**
-85,2 %
variación del periodo

**Total de la zona**
-13,3 %
variación del periodo

# Valor y volumen se separaron

Descomposición logarítmica del crecimiento del valor CIF

Producto · 10 min




**Crecimiento del valor CIF**

80,4 %

en el periodo observado

**Aporte del volumen**

52,2 %

de ese crecimiento

**Aporte del valor unitario**

47,0 %

de ese crecimiento

Los dos aportes no suman exactamente cien: la diferencia es el residuo de la descomposición y se declara. El valor CIF está en dólares corrientes, de modo que parte de la variación es precio y no volumen, y el cociente entre valor y kilogramo es un valor unitario declarado, no un precio de mercado.

Producto · 10 min

# Qué se pronostica y qué no

Un indicador que no supera la referencia trivial se presenta sin modelo

| Indicador | Observaciones | Mejor opción | Error del modelo | Repetir el último valor | Decisión |
|---|---|---|---|---|---|
| Valor CIF de importación | 173 | Historia propia + calendario | **5,875 %** | 6,956 % | **se pronostica** |
| Toneladas totales de la zona | 102 | Regresión regularizada | **6,613 %** | 9,174 % | **se pronostica** |
| Carga contenerizada | 102 | Repetir el último valor | **9,450 %** | 8,553 % | **sin modelo** |
| Contenedores equivalentes | 0 | — | — | — | **la fuente no lo publica** |
| Arribos y tiempos de atención | 0 | — | — | — | **sin fuente pública** |

### Intervalos calibrados, no supuestos

Cobertura nominal de 80 % con cobertura empírica observada entre 75,0 % y 91,7 % según el corte. La cobertura se mide, nunca se deriva del error.

### Mejora frente a la referencia

15,5 % de mejora sobre repetir el último valor en el valor CIF y 27,9 % en toneladas totales. En carga contenerizada la mejora es negativa y por eso se retira el modelo.

# Despliegue del producto: el cuadro de mando

Producto · 10 min

Contenido principal de las siete vistas y sus archivos de evidencia

### Resumen ejecutivo
Indicadores de cabecera de los dos dominios con su periodo y su fuente.

### Dinámica aduanera
Serie del valor, del peso y del valor unitario declarado, con filtros de periodo.

### Puerto y composición
Toneladas por tipo de carga y por sociedad portuaria.

### Integración y modelos
Cruce mensual, correlaciones, backtests e intervalos de predicción.

### Detalle descargable
Tablas filtrables con opción de descarga para revisar los resultados.

### Calidad y metodología
Estado de las 52 preguntas, fuentes, cobertura y definiciones.

### Navegación
Menú lateral por vista y filtros de periodo, dominio y sociedad portuaria dentro de cada una.

### Control de faltantes
Si falta un archivo, la vista avisa de cuál falta y qué comando lo genera. Nunca estima el valor ausente.

### Solo lectura
El cuadro de mando no escribe: consume lo que el proceso ya produjo y verificó.

# Demostración en vivo

Producto · 10 min

Ejemplo de uso del dashboard en cinco pasos

**streamlit run dashboard/app.py**

**1 · Resumen**
Abrir y leer los indicadores

**2 · Descriptivo**
Filtrar el periodo en aduana y puerto

**3 · Integración**
Mostrar la unión por mes

**4 · Predictivo**
Serie con intervalo y error del corte

**5 · Evidencia**
Abrir el archivo que sostiene la cifra

### Análisis descriptivo

Se filtra un periodo en la vista de puerto y se muestra cómo cambia la composición por tipo de carga; se señala el transbordo separado del comercio exterior.

### Análisis predictivo

Se abre la vista de pronóstico, se muestra el intervalo alrededor de la proyección y se compara el error contra repetir el último valor en el mismo corte.

El dashboard, el notebook y el documento consultan los mismos archivos de evidencia.

# Modelo de negocio

Lienzo de modelo de negocio aplicado al producto de datos

Cierre · 2 min

### Aliados clave

DANE · Supertransporte · Banco de la República · programa de Ciencia de Datos de la Universidad Libre

### Actividades clave

Ingesta reproducible, validación temporal y publicación de evidencia

### Recursos clave

Fuentes abiertas, código con pruebas y catálogo de preguntas

### Propuesta de valor

Leer aduana y puerto en un solo lugar, con cada cifra rastreable hasta su archivo y cada pronóstico acompañado de su error medido

### Relación con el usuario

Autoservicio guiado por el cuadro de mando y documentación abierta

### Canales

Cuadro de mando, repositorio público y documento académico

### Segmentos de usuario

Analistas de comercio exterior, planeación logística y observatorios académicos

### Estructura de costos

Cómputo local, almacenamiento de las fuentes crudas y tiempo de mantenimiento del proceso

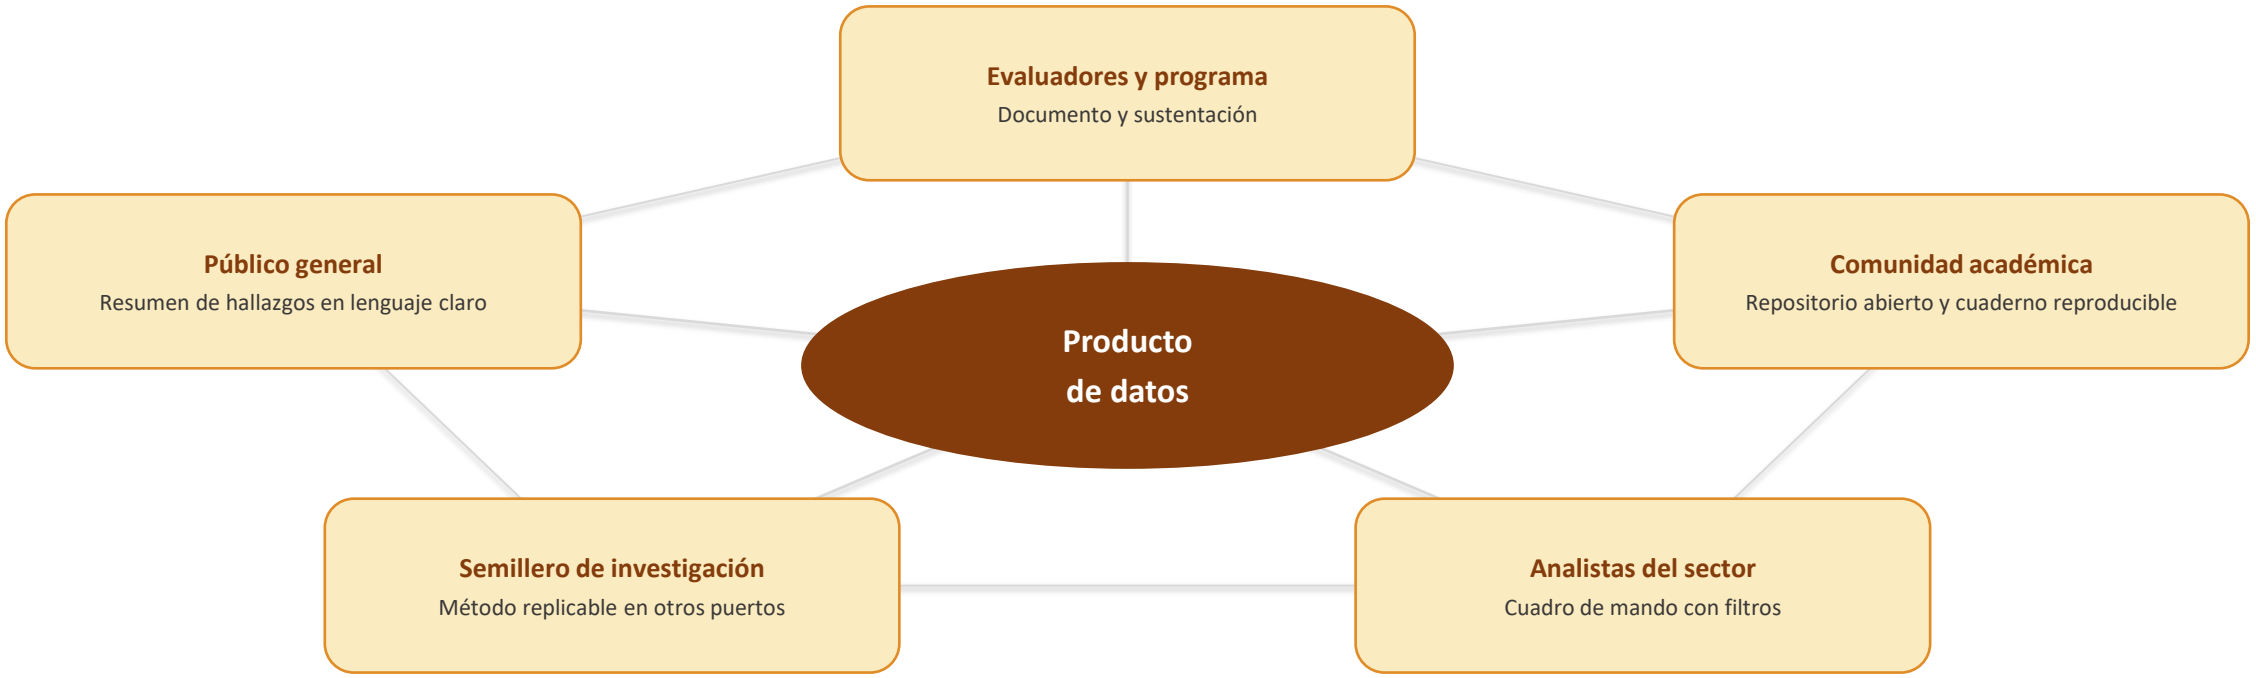
### Fuentes de ingreso

Proyecto académico sin ánimo de lucro; el retorno es el ahorro de tiempo de consulta y la reutilización del método en otros puertos

Cierre · 2 min

# Estrategias de comunicación

Mapa de red: cómo llega el producto a cada público




Cada canal recibe el mismo hallazgo con distinto nivel de detalle, y en todos los casos el hallazgo se puede rastrear hasta el archivo que lo sostiene.

Cierre · 2 min

# Conclusiones

Lo que el proyecto puede afirmar con la evidencia recogida

### 1 · La integración es explicativa, no predictiva

Añadir variables portuarias al pronóstico del valor CIF empeoró el error en 6,575 % frente a 6,082 % de la historia propia. Se midió y se reporta.

### 2 · El contraste solo existe cruzando dominios

Mercancía y orígenes variados frente a una concentración de 3.514,24 puntos por sociedad portuaria: ninguna fuente por separado permite ver ese contraste.

### 3 · Los totales agregados engañan

El total de la zona cae -13,3 % mientras la importación sube 19,6 %: la caída es transbordo, que no es comercio exterior.

### 4 · Un producto honesto declara sus límites

10 de las 52 preguntas quedaron cerradas con evidencia de por qué, y la carga contenerizada se presenta sin modelo porque ninguno superó la referencia trivial.

El producto no puede afirmar nada sobre congestión, tiempos de atención ni buques, y tampoco puede afirmar que dos sociedades dejaran de operar: solo que no aparecen reportando en los seis meses observados de 2026.

Cierre · 2 min

# Recomendaciones

Lista priorizada: qué haría más sólido el producto en su siguiente iteración

| | |
|---|---|
| Alta | **Validar las reglas de alerta con un usuario real del sector**<br>La propuesta de valor sigue siendo una hipótesis mientras nadie del público objetivo la use en una decisión. |
| Alta | **Traducir los códigos de país y de capítulo arancelario a sus nombres oficiales**<br>Hoy el cuadro de mando muestra códigos y eso limita la lectura de quien no conoce la nomenclatura. |
| Media | **Incorporar una fuente institucional sobre la operación de las sociedades portuarias**<br>Permitiría distinguir el cese de reporte del cese de operación, que hoy el proyecto no puede separar. |
| Media | **Medir la revisión de las cifras del DANE con una segunda descarga**<br>Con una sola descarga no se puede cuantificar cuánto cambian los meses ya publicados. |
| Baja | **Replicar la arquitectura en otro puerto con las mismas fuentes**<br>Comprobaría que el método es transferible y no está ajustado a Buenaventura. |

# Fuentes de información

Todas las fuentes son públicas y su descarga es reproducible

**D** — **DANE**

Microdatos de importación, aduana 35 de Buenaventura. 6.703.351 registros procesados, 2012-01 a 2026-05.

**D** — **Superintendencia de Transporte**

Tráfico portuario mensual, conjunto 5r3g-zv5z de datos.gov.co, licencia CC BY-SA 4.0. 2018-01 a 2026-06.

**C** — **Banco de la República**

Tasa representativa del mercado, serie mensual.

**C** — **NOAA**

Índice oceánico de El Niño, serie mensual.

**C** — **DIMAR**

Boletines de tráfico marítimo. Sin serie tabular histórica descargable: por eso el dominio marítimo se declara no viable.

**N** — **NTC 1486 y APA séptima edición**

Presentación del documento y citación de fuentes.

Cada archivo descargado quedó registrado con su huella digital y su fecha de consulta antes de ser procesado.

centenario
UNIVERSIDAD LIBRE
EDUCANDO EN LIBERTAD PARA LA JUSTICIA Y LA PAZ

UNIVERSIDAD LIBRE
Vigilada Mineducación

CAMINANDO EN LA EXCELENCIA

REACREDITACIÓN INSTITUCIONAL
MULTICAMPUS 2021-2027
ALTA CALIDAD
Resolución MEN n.° 015865 (25-08-2021)

www.unilibre.edu.co

Línea gratuita nacional: 01 8000 180560

@unilibrebogota | @unilibrebog | Canal Unilibre | ulibrebogota